

Simulação de Ocupação de Espectro Utilizando Modelos de Markov Escondidos

Luiz Renault Leite Rodrigues (luiz.rodrigues@dtel.inatel.br)

Instituto Nacional de Telecomunicações (INATEL) Santa Rita do Sapucaí, MG 37540-000

Abstract—Este documento tem como objetivo apresentar os resultados de experimentos de simulação de ocupação espectral utilizando o modelos de Markov Escondidos¹ no contexto da disciplina TP-547 do curso de Doutorado em Telecomunicações.

I. INTRODUÇÃO

A partir do surgimento do conceito de Rádio Cognitivo [1], tem sido investido grande esforço de pesquisa para viabilizar o uso por usuários secundários de faixas de frequências eventualmente ociosas, sem prejuízo do seu emprego pelos usuários licenciados em caráter primário.

O principal requisito para o uso compartilhado do espectro por um rádio cognitivo que opera em caráter secundário é, portanto, evitar interferência na operação do usuário primário. Com isso, torna-se fundamental para o rádio cognitivo secundário acompanhar a utilização de canais por outros usuários. Esta tarefa é realizada através do **sensoriamento espectral**.

Em áreas de aplicação sem grande exploração comercial como o setor de Segurança Pública, nota-se que muitas dos sistemas rádio utilizados são antigos e necessitam de atualização. Tem-se ainda como característica adicional a existência dos mais variados sistemas e padrões, adotados pelos diferentes órgãos existentes no país.

O rádio cognitivo se destaca neste contexto, podendo atender aos requisitos para modernização dos sistemas de telecomunicações. Um exemplo é o desenvolvimento de formas de onda de banda larga para comunicações militares em HF, com grande aplicabilidade no Rádio Definido por Software (RDS), projeto do Ministério da Defesa, e nas novas famílias de rádios desenvolvidas e fabricadas pela Indústria de Material Bélico do Brasil - IMBEL, vistos na FIG. 1.




Fig. 1. RDS Defesa (a), IMBEL TRC-1193V (b) TRC-1122 (c) e TPP-1400 (d).

O desenvolvimento das aplicações de software que rodam nestes rádios, chamadas Formas de Onda (FO), é um processo complexo e custoso, necessitando muitas vezes de centenas ou milhares de horas de trabalho para validação das implementações. Outra dificuldade observada é a escassa fonte de dados e de modelos de ocupação espectral, principalmente

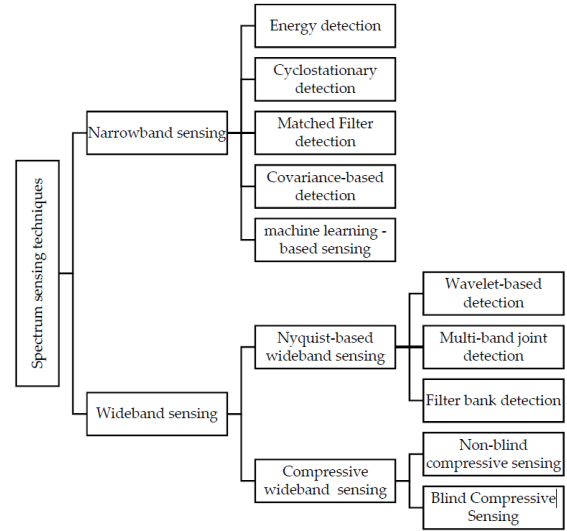


Fig. 2. Classificação de técnicas de sensoriamento espectral [2].

relacionado a aplicações mais restritas como as militares e de segurança pública. Com isso, torna-se extremamente relevante a capacidade de **simulação de tais situações utilizando modelos com parâmetros ajustados a partir de dados coletados experimentalmente**.

A abordagem clássica para o sensoriamento espectral e simulação de sistemas de comunicações baseia-se na abordagem estocástica [2].

Assim, este trabalho tem por objetivo realizar a simulação da ocupação espectral que pode ser empregada para o uso no desenvolvimento de Formas de Onda Cognitivas.

II. TRABALHOS RELACIONADOS

A tecnologia associada a rádios cognitivos já vem sendo pesquisada há mais de duas décadas e evoluiu bastante nos últimos anos. Para ajudar pesquisadores a se situarem nos avanços obtidos na temática sensoriamento espectral, [2] trás um resumo das principais técnicas e as classifica de acordo com a FIG. 2.

Tais técnicas são divididas principalmente em sensoriamento de banda estreita, ou *narrowband sensing*, e sensoriamento de banda larga, ou *wideband sensing*. O primeiro consiste na análise de um único canal de radiofrequência, enquanto o segundo analisa um conjunto de canais.

O sensoriamento de banda larga pode ser subdividido em outras duas sub-categorias: baseada em Nyquist e compressiva. Exemplos de métodos da primeira sub-categoria são a detecção baseada em *Wavelet*, a detecção conjunta multi-banda e a

¹https://github.com/luizrenault/tp547/tree/main/trabalho_final_parte_1

detecção empregando bancos de filtros. Dentre os métodos compressivos estão os de sensoriamento cegos e os não-cegos, classificados de acordo com o a necessidade de conhecimento *a priori* da esparsidade dos canais sensoreados.

Dentre os métodos empregados para o sensoriamento de banda estreita estão o de detecção de energia, detecção ciclo-estacionária, sensoriamento com filtro casado, detecção baseada em covariância, e sensoriamento baseado em aprendizado de máquina, sendo o de detecção de energia de interesse deste trabalho.

Detalhes sobre cada um destes métodos podem ser encontrados em [2] e suas referências.

Em L. R. L. Rodrigues and E. L. Pinto, “Hmm models and estimation algorithms for real-time predictive spectrum sensing and cognitive usage,” XXXV SIMPÓSIO BRASILEIRO DE TELECOMUNICAÇÕES E PROCESSAMENTO DE SINAIS - SBRt 2017, 2017 [3], referência principal deste trabalho, é mostrado o emprego de Modelos de Markov Escodidos Não Estacionários (NS-HMM) e Modelos Bivariados de Markov Escondidos (HBMM) na detecção e predição de ocupação espectral aplicados a dados reais obtidos durante as Olimpíadas e Paraolimpíadas Rio 2016. Tais modelos, após terem seus parâmetros estimados a partir de uma sequência de treinamento ou emprego adaptativo servem não só para estimar em tempo real a ocupação do espectro em banda estreita e prever a duração do estado de ocupação dado o estado atual, como também para produzir amostras simuladas com características estatísticas similares às dos dados reais modelados.




Fig. 3. Potência recebida em um canal de RF em função do tempo/amostras (direita) e frequência relativa (esquerda) [3].

A figura 3 mostra o o nível de potência de um sinal de RF, capturado às 18:58 horas do dia 7 de Setembro de 2016 durante os Jogos Olímpicos e Paraolímpicos do Rio de Janeiro, na faixa de 860 MHz, onde o Governo operava um sistema de rádio troncalizado padrão APCO25 [3].

Nela pode-se observar que ao longo do tempo/amostras o nível de potência varia entre maiores e menores valores, sendo os maiores valores observados durante a ocupação do canal pelo sistema APCO25 e os de menores valores durante a não utilização do canal.

Este sinal foi utilizado para a modelagem da ocupação espectral empregando um método de sensoriamento de banda estreita por detecção de energia com um Modelo de Markov Escondido Não Estacionário (NS-HMM). Mais detalhes sobre a modelagem e estimação dos parâmetros do modelo podem ser

encontrados no artigo, e os parâmetros estimados são mostrados em outro trabalho referenciado no artigo [4]. A seguir será apresentada uma breve explicação sobre este modelo.

O diagrama de blocos da FIG. 4 ilustra processo do sensoriamento e detecção da presença do usuário primário. O sinal recebido $r(t)$ corresponde ao sinal transmitido por um sistema primário, alterado pelo canal e pelo ruído aditivo $n(t)$.




Fig. 4. Diagrama de blocos do processo de sensoriamento espectral.

Nos algoritmos de detecção de energia para sensoriamento de banda estreita, a modelagem estatística da ocupação do canal compreende a definição de duas hipóteses dadas por:

$$r(t) = \begin{cases} n(t), & \text{Hipótese } H_1: \text{ não há outro sinal} \\ p(t) + n(t), & \text{Hipótese } H_2: \text{ há outro sinal.} \end{cases}$$

Com isso, define-se o **estado de ocupação** do canal s , onde $s = 1$ significa que a primeira hipótese é verdadeira e não há ocupação do canal, assim como $s = 2$ indica a ocupação do canal pelo usuário primário².

Dessa forma, analisando a figura 3, poderia-se tentar simular as amostras de potência do canal a partir da geração de amostras de uma distribuição mistura de gaussianas, considerando que $n(t)$ é ruído gaussiano branco com média μ_n e variância σ_n^2 e $p(t) + n(t)$ com distribuição gaussiana com média μ_p e variância σ_p^2 . Entretanto, tal metodologia geraria amostras descorrelacionadas no tempo, não sendo possível garantir nenhuma estatística relacionada à permanência em cada estado nem à troca de estados. Para solucionar este problema, outros dois modelos podem ser usados e serão resumidos a seguir.

A. Modelos de Markov Escondidos

Um Modelo de Markov Escondido é um processo estocástico capaz de modelar sistemas dinâmicos de larga escala e com dados correlacionados no tempo. Este tipo de modelo é formado por dois componentes: estados e emissões ou observações. Os estados são não observáveis e formam uma cadeia de Markov. As observações são condicionalmente independentes dados os estados e, no processo de estimação dos parâmetros do modelo, consistem nas únicas informações sobre as transições entre os estados.

Modelos HMM podem ser usados para detecção e predição da ocupação de um canal de RF pelo usuário primário.

Seja o processo estocástico duplo $\{(s_k, o_k), k = 1, \dots\}$. O primeiro, $\{s_k\}$, é o processo oculto, estacionário, de estado finito e tempo discreto, que representa a condição de ocupação do canal, podendo a variável aleatória s_k assumir valores no conjunto $\mathbb{S} = \{1, \dots, d\}$.

²Apesar do processo de detecção estar exemplificado com apenas 2 estados, um número maior de estados pode ser utilizado.

O segundo processo, $\{o_k\}$, é o processo observável, da potência do sinal recebido, que consiste em uma sequência de variáveis aleatórias reais condicionalmente independentes dada a sequência $\{s_k\}$. Isto é, para todo K inteiro não negativo $Pr(o_1^K | s_1^K) = \prod_{k=1}^K Pr(o_k | s_k)$, onde Pr denota probabilidade, sendo o_1^K e s_1^K as sequências de observações e estados nos instantes de 1 a K , respectivamente.

Admite-se que a variável aleatória o_k , nesta aplicação, possui distribuição normal com parâmetros de média e variância condicionais respectivamente μ_{s_k} e $\sigma_{s_k}^2$, dado o estado s_k .

O número de estados de ocupação d do processo oculto é chamado de ordem do modelo HMM. Assim, o modelo é capaz de representar $d - 1$ usuários primários ou cognitivos, uma vez que um dos estados normalmente está associado à desocupação do canal.

O modelo tem como parâmetros o vetor $\pi = \{\pi_a\}$ de probabilidades iniciais dos estados de ocupação, a matriz \mathbf{G} das probabilidades de transição entre os estados de ocupação, e os parâmetros das distribuições condicionais das observações, $\mathbb{O}_a = Pr(o_k | s_k = a) = \mathcal{N}(o_k, \mu_a, \sigma_a^2)$: $\mu = \{\mu_a\}$ e $\sigma^2 = \{\sigma_a^2\}$, $a = 1, \dots, d$. Define-se, então, $\phi = [\pi, \mathbf{G}, \mu, \sigma^2]$, o conjunto de parâmetros do modelo HMM, ilustrado na FIG. 5, com:

- π : vetor $1 \times d$ da distribuição de s_1 , $\{Pr(s_1 = a)\}$, $a = 1, \dots, d$, não necessariamente a distribuição estacionária;
- \mathbf{G} : matriz $d \times d$ de probabilidades de transição $\mathbf{G} = [g_{ab}]$, $g_{ab} = P(s_{k+1} = b | s_k = a)$;
- μ : vetor $1 \times d$ das médias das observações condicionadas ao estado de ocupação do canal; e
- σ^2 : vetor $1 \times d$ das variâncias das observações condicionadas ao estado de ocupação do canal;




Fig. 5. Diagrama de estado e parâmetros de um modelo HMM [4]

Pode ser mostrado que no modelo HMM a probabilidade de permanência em um mesmo estado segue uma distribuição geométrica. Seja t o tempo de permanência no estado s_k . Dados os parâmetros do modelo $\phi = [\pi, \mathbf{G}, \mu, \sigma^2]$, a probabilidade de que se permaneça em um estado a por exatamente t instantes de tempo pode ser calculada como: $Pr(s_{k+t} \neq a, s_{k+t-1} = a | s_k = a) = (g_{aa})^{t-1} (1 - g_{aa})$, $t = 1, 2, \dots$, com valor esperado do tempo de permanência igual a $\frac{1}{1 - g_{aa}}$.

B. Modelo de Markov Escondido Não Estacionário (NS-HMM)

Em [3], o modelo de Markov escondido não estacionário (NS-HMM de *non-stationary hidden Markov model*) é uti-

lizado para descrever o comportamento do usuário primário em situações em que o tempo de ocupação do canal possui distribuição arbitrária.

Neste modelo as probabilidades de transição dos estado de ocupação são funções do tempo decorrido desde a entrada no estado de partida. Isso faz com que se tenha D matrizes de probabilidades de transição associadas à permanência no estado de partida até a transição, sendo D um parâmetro do modelo.

Denotando-se por $g_{ab}(t)$ a probabilidade de transição do estado a para o estado b , t instantes de tempo após a chegada em a , é possível mostrar que a probabilidade de permanência t no estado a , $p_a(t)$ pode ser computada por:

$$p_a(t) = (1 - g_{aa}(t)) \prod_{v=1}^{t-1} g_{aa}(t) \quad (1)$$

Os valores de $p_a(t)$, por serem produtos de probabilidades de transição, estão limitados ao intervalo $[0, 1]$. Para que $\{p_a(t)\}$, $t = 1, \dots, D$ represente uma distribuição, ou seja, $\sum_t p_a(t) = 1$, é preciso que $g_{aa}(D)$ seja nulo. Isso faz com que permanências além deste valor assumam probabilidade 0.

O parâmetro D pode em princípio ser entendido como o valor da permanência máxima no estado.

No artigo é apresentada uma nova interpretação dos parâmetros do modelo:

seja $\phi = [\pi, \mathbf{G}, \mu, \sigma^2]$ o conjunto de parâmetros do modelo, com $d \times d \times D$ probabilidades de transição representadas por: $\mathbf{G} = [\mathbf{G}(t)]$, com $\mathbf{G}(t) = [g_{ab}(t)]_{d \times d}$ e $g_{ab}(t) = Pr(s_{k+1} = b | s_k^{k-t-1} = a, s_{k-t} \neq a)$, para $t = 1, \dots, D$, onde D passa a ser definido como a permanência máxima com representação arbitrária de probabilidade de ocorrência. Para valores de $t > D$, as probabilidades de transição têm o mesmo valor que com $t = D$, satisfazendo $\sum_{t=1}^{\infty} p_a(t) = 1$. Observa-se ainda que a repetição das probabilidades de transição faz com que a distribuição da permanência nos estados tenha um decaimento geométrico a partir de D .

Assim, o modelo reinterpretado mantém as características de poder representar distribuições de permanência no estado arbitrárias até um instante definido e a partir deste instante, permanências ilimitadas, distribuídas geometricamente.

O diagrama de estado e um resumo dos parâmetros podem ser vistos na FIG. 6.




Fig. 6. Diagrama de estado e parâmetros do modelo NS-HMM reinterpretado [4].

III. METODOLOGIA

Os modelos investigados serão aplicados na simulação de amostras de potência no domínio do tempo discreto, de maneira que os resultados produzidos possam ser expressos como na figura 3, permitindo a simulação da ocupação espectral que poderá ser utilizada no desenvolvimento de algoritmos cognitivos para exploração de uso secundário de faixas de frequências.

Para isso, serão utilizados os parâmetros estimados a partir dos mesmos dados capturados em [3], obtidos em [4].

Os modelos foram implementados na linguagem Python em um *Notebook Google Colab* disponibilizado no link da primeira página.

Foram considerados modelos com dois estados (canal ativo e canal inativo).

O processo de simulação utilizando os modelos HMM e NS-HMM podem ser descritos resumidamente da seguinte forma:

- 1) Geração de amostra do estado inicial a partir das distribuição de probabilidades π .
- 2) Geração de amostra de potência através de uma distribuição gaussiana com média e variância relativas ao estado atual.
- 3) Geração de amostra aleatória do estado seguinte utilizando a distribuição de probabilidades correspondente à linha do estado atual da matriz de probabilidades de transição.
- 4) Repetir a partir de 2) para o número de mostras desejadas.

IV. RESULTADOS OBTIDOS

A figura 7 exibe as amostras de potência obtidas através da simulação utilizando o modelo HMM. É possível notar que a permanência nos estados não está tão parecida quanto no caso da figura 3.




Fig. 7. Frequência Relativa e Potência simulada em um canal de RF em função do tempo/amostras utilizando o modelo HMM.

A figura 8 exibe as amostras de potência obtidas através da simulação utilizando o modelo NS-HMM reinterpretado no artigo.

É possível observar a similaridade com o sinal real capturado presente na figura 3.

Com isso, entende-se que o modelo NS-HMM pode ser utilizado para a geração de amostras de potência no domínio do tempo discreto com estatísticas bastante representativas de casos reais de ocupação espectral por usuários primários em sistemas de comunicações empregados em segurança pública.




Fig. 8. Frequência Relativa e Potência simulada em um canal de RF em função do tempo/amostras utilizando o modelo NS-HMM reinterpretado em [3].

REFERENCES

- [1] J. Mitola and G. Q. Maguire, "Cognitive radio: making software radios more personal," *IEEE Personal Communications*, vol. 6, no. 4, pp. 13–18, Aug 1999.
- [2] Y. Arjoune and N. Kaabouch, "A comprehensive survey on spectrum sensing in cognitive radio networks: Recent advances, new challenges, and future research directions," *Sensors*, vol. 19, no. 1, 2019. [Online]. Available: <https://www.mdpi.com/1424-8220/19/1/126>
- [3] L. R. L. Rodrigues and E. L. Pinto, "Hmm models and estimation algorithms for real-time predictive spectrum sensing and cognitive usage," *XXXV SIMPÓSIO BRASILEIRO DE TELECOMUNICAÇÕES E PRO-CCESSAMENTO DE SINAIS - SBRT 2017*, 2017.
- [4] L. R. L. Rodrigues, "Modelos hmm para predição de ocupação de canais em sistemas rádio cognitivos," Master's thesis, Instituto Militar de Engenharia, Apr 2017.